Нейросетевые методы для СДУ Ито

Общая постановка задачи и три подхода из литературы

Одномерный случай; без физической интерпретации

Статья 1: Y. Gu, J. Harlim, S. Liang, H. Yang,
Stationary Density Estimation of Itô Diffusions Using Deep Learning, 2021.

https://arxiv.org/abs/2109.03992

Статья 2: N. Kiyohara, E. Johns, Y. Li. *Neural Stochastic Flows*, NeurIPS 2025.

https://arxiv.org/abs/2510.25769

Статья 3: A. Zhu, Q. Li. *DynGMA: a robust approach for learning SDEs from data*, 2024.

https://arxiv.org/abs/2402.14475

Общая задача

Цель

Построить **нейросетевой вероятностный прогноз** по наблюдениям и проверить его **надёжность на длинных горизонтах**.

1. Подготовить временной ряд и данные для обучения/проверки.
2. Обучить модель динамики; в общей постановке предусмотреть коррекцию по наблюдениям.
3. Получать ансамбль прогнозов и оценивать неопределённость.
4. Исследовать устойчивость и предельные распределения.
5. Сравнить с классической моделью по точности и затратам.

Основа: «Задача.txt», пункты 1–5; здесь – сознательное упрощение до одномерного ряда.

Математическая постановка первого этапа

$$dX_t = a(X_t)\,dt + b(X_t)\,dW_t$$

Дано: дискретные наблюдения $x_0, x_1, \ldots, x_N$ с шагом Δt; a, b неизвестны.

Вероятностный прогноз

$p_\Delta(y \mid x) = p(X_{t+\Delta t} = y \mid X_t = x)$

Нужен для прогноза и ансамблей.

Долгосрочная статистика

$p_\infty(x) = \lim_{t\to\infty} p(t, x)$

Нужна для анализа устойчивости.

Что решает статья Gu et al.

Именно **вторую задачу**: восстановление стационарной плотности p_∞ по временному ряду при предположении эргодичности.

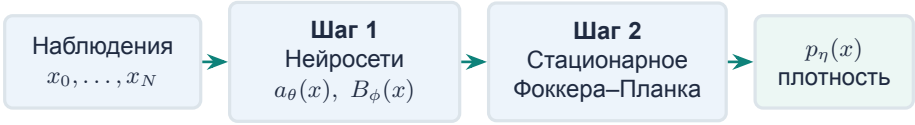
Обозначения: общая постановка

X_t	случайный процесс	$q_\Delta(y \mid x)$	переходная плотность
x_i	значение ряда в момент t_i	$p(t, y)$	плотность X_t
W_t	винеровский процесс	$p_\infty(y)$	предельная плотность
$a(x)$	коэффициент сноса	θ, ϕ, η, ξ	веса разных сетей
$b(x)$	амплитуда шума	$\mathcal{L}$	функция потерь
Δ	временной интервал $t - s$	L	слои / шаги (контекст)

Разница двух плотностей

$q_\Delta(y \mid x)$ задаёт **переход из состояния** x; $p_\infty(y)$ описывает **долгосрочную статистику** и существует не всегда.

Gu et al.: базовая концепция



- **Сначала** идентифицируется стохастическая динамика: $a(x)$ и $B(x) = b^2(x)$.
- **Затем** третья нейросеть аппроксимирует стационарную плотность как решение PDE.

Gu et al., arXiv:2109.03992, §§2–3, формулы (1)–(3), (6)–(13)

Gu et al.: обозначения параметров

Модель коэффициентов

$$a_\theta(x) \approx a(x),$$
$$B_\phi(x) \approx b^2(x).$$

θ — веса сети сноса.

ϕ — веса сети квадрата диффузии.

Модель плотности

$$p_\eta(x) \approx p_\infty(x),$$
$$\mathcal{L}_p(\eta) \longrightarrow \min.$$

η — веса сети плотности.

λ_1, λ_2 — веса ограничений в $\mathcal{L}_p$.

Не путать

$B(x) = b^2(x)$ — **дисперсия шума в единицу времени**; θ, ϕ, η — не значения X_t, а настраиваемые веса разных нейросетей.

Gu et al., arXiv:2109.03992, §3.2–3.3, формулы (6), (9), (10)–(17)

Шаг 1a: восстановление сноса

$$\Delta X_n = X_{n+1} - X_n \approx a(X_n)\Delta t + b(X_n)\sqrt{\Delta t}\,\xi_n,$$
$$Y_n = \frac{X_{n+1} - X_n}{\Delta t}, \quad \xi_n \sim \mathcal{N}(0,1).$$

$$\boxed{\mathcal{L}_a(\theta) = \frac{1}{N}\sum_{n=0}^{N-1}\big(Y_n - a_\theta(X_n)\big)^2}$$

Идея

$\mathbb{E}[Y_n \mid X_n = x] \approx a(x)$. Обучение сводится к обычной регрессии по приращениям ряда.

Gu et al., arXiv:2109.03992, §3.2, формулы (3), (5)–(7)

Шаг 1б: восстановление диффузии

После оценки a_θ берём остатки $r_n = Y_n - a_\theta(X_n)$.

$$\mathcal{L}_B(\phi) = \frac{1}{N}\sum_{n=0}^{N-1}\left(\Delta t\, r_n^2 - B_\phi(X_n)\right)^2$$

Вариант A: $B(x)$ **неизвестная функция**

Обучаем отдельную сеть $B_\phi(x) \approx b^2(x)$.

Вариант B: $B(x) = \sigma^2$ **постоянна**

$$\widehat{\sigma^2} = \frac{\Delta t}{N}\sum_{n=0}^{N-1} r_n^2.$$

Вторая сеть не нужна.

Gu et al., arXiv:2109.03992, §3.2, формулы (8)–(9); функция потерь масштабирована на Δt^2

Шаг 2: стационарная плотность

Заменяем неизвестные коэффициенты на a_θ и B_ϕ:

$$\boxed{\widehat{\mathcal{L}}^* p_\eta(x) = -\frac{d}{dx}(a_\theta p_\eta) + \frac{1}{2}\frac{d^2}{dx^2}(B_\phi p_\eta) \approx 0}$$

На ограниченной области $\Omega = [-R, R]$ обучаем третью сеть:

$$\mathcal{L}_p(\eta) = \int_\Omega |\widehat{\mathcal{L}}^* p_\eta|^2 dx + \lambda_1 \left(\int_\Omega p_\eta \, dx - 1 \right)^2 + \lambda_2 \|p_\eta\|^2_{L^2(\partial\Omega)}.$$

Численная реализация из статьи

Интегралы: квадратуры или Монте-Карло. Дополнительно контролируют нормировку, границу и положительность.

Gu et al., arXiv:2109.03992, §3.3, формулы (10)–(17)

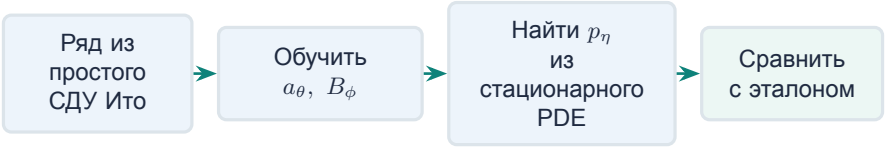
Какие варианты действительно рассматривает статья

1. **Оценка диффузии:** сеть $B_\phi(x)$ или постоянная матрица/константа по остаткам (§3.2).
2. **Архитектура:** полносвязная сеть (FNN) или ResNet для аппроксимации коэффициентов (§3.1, 5).
3. **Обучение плотности:** невзвешенный остаток PDE на Ω или взвешенный по эмпирическим точкам ряда (§3.3, 5).
4. **Интегрирование:** Монте-Карло; в малой размерности возможны квадратуры (§3.3).

Не рассматривается в этой статье

Прямое обучение $p(X_{t+\Delta t} \mid X_t)$ и эволюции $p(t, x)$: это другие задачи.

Что можем сделать в 1D на первом этапе



Простой тест: $dX_t = -\kappa X_t dt + \sigma dW_t$, $\kappa > 0$.

$$p_\infty(x) = \sqrt{\frac{\kappa}{\pi\sigma^2}}\exp\left(-\frac{\kappa x^2}{\sigma^2}\right)$$

Проверить: коэффициенты a, B; нормировку p_η; ошибку плотности и статистику длинных траекторий. **Это предлагаемый нами эксперимент, не пример из статьи.**

Gu et al., arXiv:2109.03992, Примеры авторов: §5, двумерное распределение Стьюдента и 20D Langevin

Подход Gu et al.: итог и ограничения

Практический результат

Метод позволяет по одному дискретному ряду оценить $a(x)$, $b^2(x)$ и **стационарную плотность** $p_\infty(x)$.

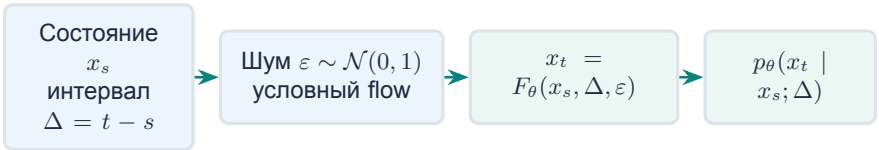
- Требуются эргодичность и корректность стохастической модели.
- Влияют ошибки дискретизации, регрессии коэффициентов и решения PDE.
- Для условной плотности $p(X_{t+\Delta t} \mid X_t)$ рассмотрим другой метод: Neural Stochastic Flows.

Источник: Y. Gu, J. Harlim, S. Liang, H. Yang. *Stationary Density Estimation of Itô Diffusions Using Deep Learning*. 2021. `https://arxiv.org/abs/2109.03992`

Подход 2: Neural Stochastic Flows (NSF)

Идея статьи Kiyohara, Johns, Li (2025)

Обучать **не коэффициенты СДУ**, а непосредственно **переходную плотность** $p_\theta(x_t \mid x_s;\, t-s)$ без численного решения СДУ.



- **Normalizing flow:** обратимые преобразования позволяют вычислять плотность.
- Переход на произвольный Δ внутри обученного горизонта — за один вызов сети.

Kiyohara, Johns, Li, NeurIPS 2025, arXiv:2510.25769, §§1, 3; рис. 1; формулы (2)–(3)

NSF: обозначения и параметры

$s < t$	начало / конец	F_θ	обратимое преобразование
$\Delta = t - s$	горизонт прогноза	θ	веса основной сети
$c = (x_s, \Delta)$	условие модели	q_θ	переходная плотность
ε	стандартный нормальный шум	L	число слоёв flow
z	базовая случайная величина	$\mathcal{L}$	функция потерь

Если динамика зависит от абсолютного времени

Во входы добавляют время начала: $c = (x_s, s, \Delta)$.

Kiyohara, Johns, Li, NeurIPS 2025, arXiv:2510.25769, §3.1, формулы (3), (5)–(7)

NSF: свойства переходной плотности

Для $s < u < t$ обозначим $q_\theta(y \mid x; s, t) = p_\theta(X_t = y \mid X_s = x)$.

Тождественность: $q_\theta(y \mid x; s, s) = \delta(y - x)$,

Чепмен–Колмогоров: $q_\theta(z \mid x; s, t) = \int_{\mathbb{R}} q_\theta(z \mid y; u, t) q_\theta(y \mid x; s, u)\, dy.$

Автономное СДУ

При $a = a(x)$ и $b = b(x)$ переходное ядро **не зависит от начального времени**: $q_\theta(y \mid x; s, t) = q_\theta(y \mid x;\, t - s)$.

Важно: временная однородность переходов не означает существования стационарной плотности p_∞.

Kiyohara, Johns, Li, NeurIPS 2025, arXiv:2510.25769, §3, формула (4), свойства identity / Markov / stationarity

Как устроена модель NSF

Базовое распределение (здесь показана одномерная запись):

$$z = x_s + \Delta\, m_\theta(x_s, \Delta) + \sqrt{\Delta}\, s_\theta(x_s, \Delta)\varepsilon, \quad \varepsilon \sim \mathcal{N}(0,1).$$

Преобразование: $x_t = F_\theta(z;\, x_s, \Delta)$, где F_θ обратимо.

Оригинальная многомерная архитектура

Авторы применяют **affine coupling layers**: для разбиения $z = (z_A, z_B)$

$$z'_A = z_A, \qquad z'_B = z_B \odot \exp\{\Delta S_\theta(z_A, c)\} + \Delta T_\theta(z_A, c).$$

При $\Delta = 0$: базовое распределение вырождается в x_s, преобразование становится тождественным.

Особенность 1D: обычное разбиение z_A, z_B для скалярного состояния неприменимо; нужен отдельный одномерный обратимый flow (наша адаптация).

Kiyohara, Johns, Li, NeurIPS 2025, arXiv:2510.25769, §3.1, формулы (5)–(7); приложение A.1

Почему плотность вычисляется явно

Пусть $z \sim \mathcal{N}(\mu_\theta, \sigma_\theta^2)$ и $y = F_\theta(z; c)$, $c = (x_s, \Delta)$. Для обратимого дифференцируемого F_θ:

$$p_\theta(y \mid x_s; \Delta) = \frac{\mathcal{N}\big(F_\theta^{-1}(y; c); \mu_\theta, \sigma_\theta^2\big)}{\big|\partial_z F_\theta\big(F_\theta^{-1}(y; c); c\big)\big|}.$$

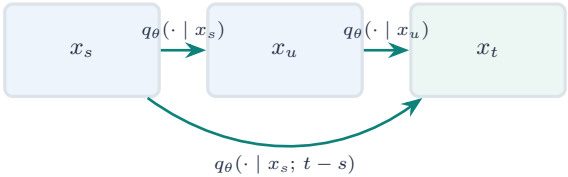
Обучение по наблюдаемым парам

Для набора $\mathcal{D} = \{(x_{t_i}, x_{t_j}, \Delta_{ij})\}$:

$$\mathcal{L}_{\text{NLL}}(\theta) = -\frac{1}{|\mathcal{D}|} \sum_{(i,j)\in\mathcal{D}} \log p_\theta(x_{t_j} \mid x_{t_i}; \Delta_{ij}).$$

Kiyohara, Johns, Li, NeurIPS 2025, arXiv:2510.25769, §3.1–3.2, формула (11); приложение D, формула (36)

Согласованность прогнозов на разных горизонтах



Задача: согласовать прямой прогноз $s \to t$ и составной $s \to u \to t$.

$$q_\theta^{(2)}(z \mid x) = \int q_\theta(z \mid y; u, t) q_\theta(y \mid x; s, u)\, dy.$$

Функция потерь из статьи

$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{NLL}} + \lambda \mathcal{L}_{\text{flow}}$, где $\mathcal{L}_{\text{flow}}$ минимизирует **вариационные верхние оценки** двух направлений KL: $D_{\text{KL}}(q^{(1)} \| q^{(2)})$ и $D_{\text{KL}}(q^{(2)} \| q^{(1)})$.

Kiyohara, Johns, Li, NeurIPS 2025, arXiv:2510.25769, §3.2, формулы (4), (8)–(11); рис. 1(c,d)

Как вычисляют $\mathcal{L}_{\text{flow}}$

Поскольку $q^{(2)}$ содержит интеграл по x_u, вводится **мостовая сеть** $b_\xi(x_u \mid x_s, x_t)$ для промежуточного состояния. **Прямое направление (1 → 2):**

$$\mathcal{L}_{1\to 2} = \mathbb{E}_{x_t\sim q^{(1)},\, x_u\sim b_\xi} \log \frac{q^{(1)}(x_t \mid x_s)\, b_\xi(x_u \mid x_s, x_t)}{q_\theta(x_t \mid x_u)\, q_\theta(x_u \mid x_s)}.$$

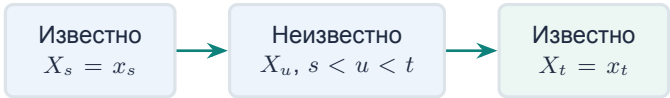
Обратное направление (2 → 1):

$$\mathcal{L}_{2\to 1} = \mathbb{E}_{x_u\sim q_\theta(\cdot|x_s),\, x_t\sim q_\theta(\cdot|x_u)} \log \frac{q_\theta(x_u \mid x_s)\, q_\theta(x_t \mid x_u)}{b_\xi(x_u \mid x_s, x_t)\, q^{(1)}(x_t \mid x_s)}.$$

Итого: $\mathcal{L}_{\text{flow}} = \mathbb{E}_{s<u<t}[\mathcal{L}_{1\to 2} + \mathcal{L}_{2\to 1}]$.

Kiyohara, Johns, Li, NeurIPS 2025, arXiv:2510.25769, §3.2, формулы (8)–(10); приложения A.2 и B

NSF: что такое мостовая сеть b_ξ?



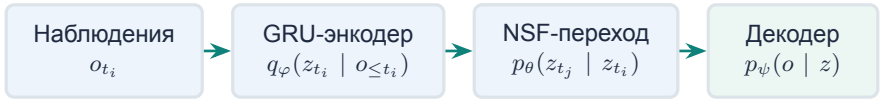
$$b_\xi(x_u \mid x_s, x_t; s, u, t) \approx p(X_u = x_u \mid X_s = x_s, X_t = x_t)$$

- ξ — **веса вспомогательной нейросети**, а не коэффициент диффузии $b(x)$ в СДУ.
- Мостовая сеть выдаёт **распределение возможного промежуточного состояния** при фиксированных концах.
- Нужна для вычислимой регуляризации согласованности «прямой переход = два перехода».

Kiyohara, Johns, Li, NeurIPS 2025, arXiv:2510.25769, §3.2, формулы (8)–(10); приложение A.2, формулы (19)–(21)

Второй вариант из статьи: Latent NSF

При **неполных или зашумлённых наблюдениях** o_{t_i} вводится скрытое состояние z_{t_i}.



Обучение

$\mathcal{L}_{\text{latent}} = \mathcal{L}_{\beta\text{-NELBO}} + \lambda \mathcal{L}_{\text{flow}} + \beta_{\text{skip}} \mathcal{L}_{\text{skip}}$.

$\mathcal{L}_{\text{skip}}$ сопоставляет прямой многократный по времени переход с апостериорным распределением будущего скрытого состояния.

Для первого 1D-эксперимента: если x_t наблюдается непосредственно, Latent NSF пока не требуется.

Kiyohara, Johns, Li, NeurIPS 2025, arXiv:2510.25769, §4, формулы (12)–(18), рис. 2

Что можем применить в нашей одномерной задаче

Вариант A: простой baseline

Только гауссова база:

$$X_{t+\Delta} \mid X_t = x \sim \mathcal{N}(\mu_\theta, v_\theta),$$

$\mu_\theta = x + \Delta m_\theta(x, \Delta)$,
$v_\theta = \Delta s_\theta^2(x, \Delta)$.
Обучение: $\mathcal{L}_{\text{NLL}}$.

Вариант B: гибкая плотность

Добавить **скалярный монотонный обратимый** F_θ, $F_{\theta,0} = \text{id}$.

$$X_{t+\Delta} = F_\theta(z;\, x, \Delta).$$

Обучение: $\mathcal{L}_{\text{NLL}} + \lambda \mathcal{L}_{\text{flow}}$.

Граница между статьёй и нашей адаптацией

Из статьи: Gaussian base, условные обратимые преобразования, flow loss.
Наше 1D-упрощение: без coupling-слоёв в A; скалярный invertible flow вместо coupling в B.

Kiyohara, Johns, Li, NeurIPS 2025, arXiv:2510.25769, §3.1–3.2, формулы (5)–(11); 1D-архитектуры — предлагаемые адаптации

Проверочный эксперимент для NSF

Модель: процесс Орнштейна–Уленбека, $dX_t = -\kappa X_t dt + \sigma dW_t$, $\kappa > 0$.

$$X_{t+\Delta} \mid X_t = x \sim \mathcal{N}\left(x e^{-\kappa\Delta},\ \frac{\sigma^2}{2\kappa}(1 - e^{-2\kappa\Delta}) \right).$$



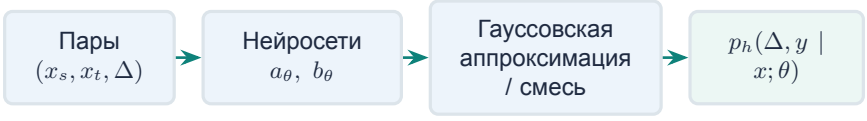
Метрики: test NLL; ошибки среднего/дисперсии; ошибка Чепмена–Колмогорова; время прогноза на разных Δ. **Это наш эксперимент:** в статье тесты на стохастическом Лоренце, движениях человека и видео.

Kiyohara, Johns, Li, NeurIPS 2025, arXiv:2510.25769, §6, экспериментальные постановки; OU — предлагаемая проверка

DynGMA: основная концепция статьи

Идея Zhu, Li (2024)

По дискретным данным **обучить снос и диффузию** СДУ, но вместо приближения Эйлера использовать **более точную переходную плотность**.



- **Одна гауссиана:** дёшево, подходит для небольших интервалов.
- **Смесь гауссиан:** точнее описывает нелинейный переход при больших Δ.

A. Zhu, Q. Li, DynGMA, arXiv:2402.14475 (2024), §§2–3, формулы (3)–(9); рис. 1

DynGMA: определения переменных

a_θ, b_θ	сети сноса и диффузии	L	шаги ОДУ на интервале h
θ	веса сетей	m_i, V_i	среднее и дисперсия
Δ	интервал наблюдений	w_i, I_k	вес / число компонент
K	число подынтервалов	ξ_j, ω_j	узлы / веса квадратуры
$h = \Delta/K$	длина подынтервала	$\mathcal{L}$	функция потерь

Важно: смысл L зависит от статьи

NSF: число слоёв normalizing flow. **DynGMA:** число шагов вычисления m, V внутри h. $\mathcal{L}$ — функция потерь.

A. Zhu, Q. Li, DynGMA, arXiv:2402.14475 (2024), §3.1–3.2, формулы (8)–(15); Algorithm 1

DynGMA: чем улучшают Эйлера–Маруяму?

Восстанавливаем коэффициенты $dX_t = a_\theta(X_t)dt + b_\theta(X_t)dW_t$.

Обычное приближение Эйлера–Маруямы

$$p_{\mathsf{EM}}(h, y \mid x) = \mathcal{N}\big(y;\, x + h a_\theta(x),\, h b_\theta^2(x)\big)\,.$$

DynGMA: среднее m и дисперсию V вычисляют из **детерминированных ОДУ**:

$$\dot m = a_\theta(m), \qquad \dot V = 2a'_\theta(m)V + b^2_\theta(m), \quad m(0) = x,\ V(0) = 0.$$

На каждом интервале h: $p_{\mathsf{G}}(h, y \mid x) = \mathcal{N}(y; m(h), V(h))$.

A. Zhu, Q. Li, DynGMA, arXiv:2402.14475 (2024), §2, (5); §3.2, (13)–(14). ОДУ — скалярная запись уравнений статьи

DynGMA: два алгоритма для одной гауссианы

Алгоритм 1 — интегрировать ОДУ для m, V

- На интервале h сделать L численных шагов схемы (14).
- Результат: $p_{\mathsf{G}}(h, y \mid x) = \mathcal{N}(y; m_L, V_L)$.

Алгоритм 2 — быстрый вариант, без разложения Холецкого

$$\boxed{\begin{aligned} x_{1/2} &= x + \frac{h}{2} a_\theta(x), \\ m &= x + h\, a_\theta(x_{1/2}), \\ V &= h\, b_\theta^2(x_{1/2}). \end{aligned}}$$

Выбор

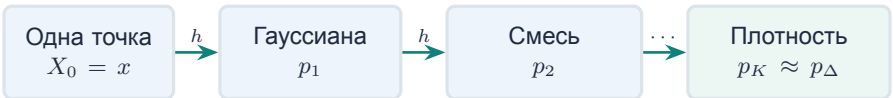
$K = 1$: **одно гауссовское приближение**; Algorithm 2 быстрее, Algorithm 1 допускает уточнение через L. При $K > 1$ их используют внутри смеси.

A. Zhu, Q. Li, DynGMA, arXiv:2402.14475 (2024), §3.2, (14)–(15), Algorithm 1–2, теоремы 3.2–3.4; формулы приведены для 1D

DynGMA: переход от гауссианы к смеси

Интервал Δ разбивают на K шагов длины $h = \Delta/K$. После шага k аппроксимируют плотность смесью:

$$p_k(y \mid x) \approx \sum_{i=1}^{I_k} w_i^{(k)} \mathcal{N}\left(y; m_i^{(k)}, V_i^{(k)}\right).$$



Обновление смеси основано на **уравнении Чепмена–Колмогорова** и квадратурном приближении интегралов.

A. Zhu, Q. Li, DynGMA, arXiv:2402.14475 (2024), §3.1, (8)–(9), рекурсия перед Algorithm 1; рис. 1

DynGMA: как обновляется смесь в 1D

Для каждой компоненты $\mathcal{N}(m_i, V_i)$ берём точки квадратуры:

$$x_{ij} = m_i + \sqrt{V_i}\,\xi_j, \quad \{\xi_j\}_{j=0}^{2} = \{0, +\sqrt{2}, -\sqrt{2}\}, \quad \{\omega_j\} = \left\{\frac{1}{2}, \frac{1}{4}, \frac{1}{4}\right\}.$$

В каждой точке рассчитываем $m_h(x_{ij})$, $V_h(x_{ij})$ по Gaussian-шагу:

$$p_{k+1}(y \mid x) \approx \sum_{i=1}^{I_k} \sum_{j=0}^{2} w_i^{(k)} \omega_j \, \mathcal{N}(y; m_h(x_{ij}), V_h(x_{ij})).$$

Число компонент

$w_{ij}^{(k+1)} = w_i^{(k)} \omega_j, \quad I_{k+1} = 3I_k$ (для выбранной одномерной квадратуры).

Большой K повышает гибкость, но увеличивает стоимость вычислений.

A. Zhu, Q. Li, DynGMA, arXiv:2402.14475 (2024), §3.1, формулы смеси; §4, симметричная кубатура, рис. 1

DynGMA: обучение по временным рядам

Для пар наблюдений $\mathcal{D} = \{(x_i, x_{i+1}, \Delta_i)\}$ обучаем a_θ, b_θ методом максимального правдоподобия:

$$\mathcal{L}_{\text{MLE}}(\theta) = -\frac{1}{|\mathcal{D}|} \sum_i \log p_h(\Delta_i, x_{i+1} \mid x_i; \theta).$$

Многошаговый вариант из статьи: дополняем пары переходами на γ наблюдений вперёд:

$$\mathcal{L}_{\text{multi}}(\theta) = -\sum_{\gamma \in \Gamma} \frac{1}{N_\gamma} \sum_{i \in \mathcal{I}_\gamma} \log p_h(t_{i+\gamma} - t_i, x_{i+\gamma} \mid x_i; \theta).$$

Γ — выбранные горизонты; $N_\gamma = |\mathcal{I}_\gamma|$. Нормировка по числу пар — наша эквивалентная для выбора масштаба запись.

A. Zhu, Q. Li, DynGMA, arXiv:2402.14475 (2024), §2, (4)–(7); §3.3, (17)–(18), многошаговое обучение

DynGMA: одномерная проверка в статье

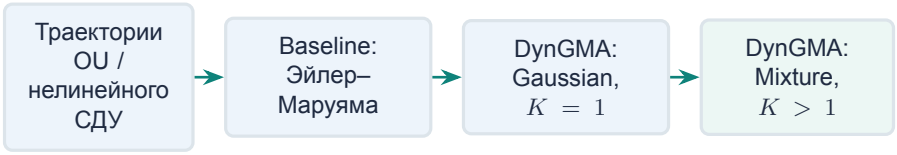
Пример Beneš (§4.1):

$$dX_t = \tanh(X_t)\,dt + dW_t, \qquad \boxed{p(t, y \mid x) = \frac{\cosh y}{\cosh x}\,\frac{e^{-t/2}}{\sqrt{2\pi t}}\,\exp\!\left(-\frac{(y-x)^2}{2t}\right).}$$

- **Рис. 2 статьи (с. 14):** DynGMA ближе к точной плотности при больших t, чем одношаговый Эйлер.
- **Приложение C:** дополнительно обучают коэффициенты одномерного СДУ с шумом $0.3\,dW_t$.
- **Важно:** пример оценивает *переходную* плотность; стационарная плотность здесь не исследуется.

A. Zhu, Q. Li, DynGMA, arXiv:2402.14475 (2024), §4.1, рис. 2; приложение C, таблица C.4

Что применить к нашей одномерной задаче



1. Одинаковые пары $\mathcal{D}$; обучить a_θ, b_θ каждым способом.
2. Проверить переходные плотности $p(\Delta, y \mid x)$ на **нескольких** Δ.
3. Сравнить test NLL, ошибки a, b, точность распределения и стоимость.
4. Если процесс эргодичен, отдельно исследовать p_∞ (**задача Gu**).

Наш эксперимент, не результат статьи. В статье условия теорем оценивают приближение случайной величины, а не непосредственно ошибку обученных коэффициентов.

A. Zhu, Q. Li, DynGMA, arXiv:2402.14475 (2024), §3, методы; §4.1–4.2, эксперименты; теоремы 3.2–3.4

Сопоставление трёх подходов

Gu et al.

Цель: $p_\infty(x)$.

Обучение: a, b^2 и сеть плотности.

Оператор: стационарный Фоккер–Планк.

Neural SF

Цель: $p_\theta(y \mid x; \Delta)$.

Обучение: условный normalizing flow.

Условие: Chapman–Kolmogorov (приближённо).

DynGMA

Цель: $p_h(\Delta, y \mid x)$.

Обучение: a, b через MLE.

Оператор: Gaussian / mixture переходное ядро.

Для первого эксперимента: Эйлер–Маруяма $\to$ DynGMA ($K = 1$) $\to$ DynGMA ($K > 1$); затем сопоставить с NSF и стационарной плотностью.

Gu et al. (2021), arXiv:2109.03992; Kiyohara et al. (2025), arXiv:2510.25769; Zhu, Li (2024), arXiv:2402.14475.